

MaskCO: Masked Generation Drives Effective Representation Learning and Exploiting for Combinatorial Optimization

26.07.23

노정빈



❖ 기존 NCO 패러다임의 한계

- ✓ Construction 계열 (AM, POMO, BQ-NCO, LEHD ...): RL 기반 순차 구성 — sparse reward, 오류 누적
- ✓ 생성형/Heatmap 계열 (DIFUSCO, T2T, Fast T2T ...): diffusion으로 해 전체를 일괄 생성 — 반복 추론 고비용
- ✓ 공통된 근본 한계: 해를 통으로 취급
 - (인스턴스, 해) 쌍 하나 = 학습 신호 하나 → 데이터 활용 비효율
 - 해 내부의 국소 결정 패턴(부분 경로, 노드 군집)은 학습에 미활용
 - supervision 확보 비용이 큰 CO에서 특히 치명적


❖ NLP·비전의 Self-supervised 사전학습

- ✓ task별 라벨 의존 → BERT(마스킹 복원) · GPT(다음 토큰) · MAE의 사전학습으로 극복
- ✓ 연구 질문: CO에도 같은 사전학습 패러다임이 가능한가?

I 핵심 아이디어: Masked Generation

❖ 최적해의 일부를 가리고, 이를 복원하도록 학습

- ✓ 최적해도 문장·이미지처럼 반복되는 국소 부분구조를 포함
- ✓ 마스킹 비율 $\rho \sim U[0,1] \rightarrow$ 해 하나를 많은 (인스턴스, 부분해) 하위 예제로 분리



❖ CO를 그래프 전체집합 $U(G)$ 의 부분집합 선택으로 통일

- ✓ 간선 선택 문제 (TSP): $U(G) = E$ / 노드 선택 문제 (MIS): $U(G) = V$
- ✓ 해 표현: 이진 벡터 x
 $x_u = 1$ 은 $u \in U(G)$ 가 선택되었음을 의미
- ✓ 목표: $\min_{x \in \Omega(G)} l(x; G)$ ($\Omega(G)$: feasible set)
- ✓ 제약 처리: 문제에 따라 feasibility(Ω)로 강제하거나 목적함수 $l(\cdot; G)$ 내의 페널티로 강제

❖ 부분해 $\hat{x}$ (binary vector)

- ✓ $\hat{x}$ 는 $\hat{x} \leq x'$ 를 만족하는 feasible 해 x' 가 존재하는 이진 벡터 $\rightarrow G$ 에 대한 부분해

❖ 선택 함수 $f_G(\hat{x}, p, k)$

- ✓ 부분해 $\hat{x}$ + 선택 점수 p + 목표 크기(또는 maximality) k 를 받아 확장된 부분해 반환
 $\rightarrow$ 단조성: $\hat{x} \leq f_G(\hat{x}, p, k)$
 $\rightarrow$ 목표 크기 도달 또는 maximality까지 확장: $|f_G(\hat{x}, p, k)| \geq k$
- ✓ 전형적 구현 = greedy: 점수 p 내림차순으로, 확장 가능성이 유지되는 원소만 하나씩 추가
 $\rightarrow$ 예: TSP는 해밀턴 사이클 유지가 가능한 간선만 추가 (차수 ≤ 2 , 조기 서브투어 금지)

❖ 학습 iteration 단계

- ① 비율 $\rho \sim D_\rho (= [0, 1])$ 를 샘플링 $\rightarrow$ 최적해 x^* 에서 $\lceil \rho \cdot |x^*| \rceil$ 개 원소를 균일하게 유지하고 나머지 마스킹 $\rightarrow$ 부분해 $\hat{x}$ 구성
- ② 모델이 예측한 선택 확률: $p_\theta(G, \hat{x}) \in [0, 1]^{|U(G)|}$
- ③ 변수별 Binary Cross-Entropy로 학습 (타겟 = 완전한 최적해 x^*)

$$\mathcal{L}(\theta; G, \hat{x}, x^*) = \text{BCE}(p_\theta(G, \hat{x}), x^*) = - \sum_{u \in U(G)} [x_u^* \log p_{\theta,u} + (1 - x_u^*) \log (1 - p_{\theta,u})]$$

❖ Point

- ✓ 각 마스킹 위치 = 독립적인 이진 분류 $\rightarrow$ 현재 맥락을 바탕으로 변수가 최적 솔루션에 속하는지 여부를 예측하는 방법을 학습
- ✓ 매 iteration 다른 마스킹 $\rightarrow$ 하나의 해에서 다양한 추론 경로에 노출

II 모델 구조: Encoder-Decoder Transformer

❖ 인코더 - Self-Attention Transformer: 인스턴스 이해

- ✓ 입력: 노드 좌표의 선형 투영 (부분해와 무관)
- ✓ self-attention으로 노드 쌍 관계(거리·배치 구조)를 담은 노드 임베딩 생성 → 인스턴스당 1회만 실행, 이후 재사용

❖ 디코더 - Self-Attention Transformer: 부분해 조건부 복원

- ✓ 입력 토큰: 인코더 임베딩(투영) + 마스킹 비율 p 의 timestep embedding (diffusion 방식)
- ✓ 부분해 주입: 인접행렬 A 를 attention 로짓에 가산 $Z = Q^T K + A \rightarrow$ 부분해로 연결된 노드 쌍에 주의 강화
- ✓ 교정 반복에서 재호출되는 것은 이 얇은 디코더뿐 → 속도 우위

❖ Q·K·V

- ✓ $Q(\text{질의}) \cdot K(\text{키}) \cdot V(\text{값})$ 모두 노드 임베딩의 선형 변환: $Q^T K$ 로 노드 쌍 유사도 계산, V 를 유사도 가중합
- ✓ 디코더에서는 $Q^T K$ 에 A 가 더해져 "인스턴스 기하 + 현재 부분해"를 동시에 반영

❖ 출력 헤드

- ✓ 간선 선택(TSP): 노드 임베딩 쌍의 내적 → $N \times N$ 히트맵
- ✓ 노드 선택(MIS): 1차원 투영 → 노드 로짓

Table 11: Neural network configurations.

	TSP	CVRP	MIS-RB-[200-300]	MIS-ER-[700-800]
embedding dimension	256	512	256	256
head dimension	32	64	64	64
encoder layers	16	16	0	0
decoder layers	6	6	12	24

❖ 설정

- ✓ K : 스텝 수 (몇 번의 호출로 나눌지)
- ✓ 스케줄 함수 $\gamma: [0,1] \rightarrow [0,1]$ (각 호출에서 얼마나 채울지)
논문에서는 선형 증가 함수 채택 $\gamma(t) = t$

❖ 고정 크기 문제 (TSP: $m = |V|$)

- ✓ 빈 해 $\hat{x}^{(0)} = \emptyset$ 에서 시작, 스텝 i 마다 히트맵을 새로 예측하고 greedy로 $\lceil \gamma(i/K) \cdot m \rceil$ 개의 노드 또는 간선 선택

$$\hat{x}^{(i)} \leftarrow f_G(\hat{x}^{(i-1)}, p_\theta(G, \hat{x}^{(i-1)}), \lceil \gamma(i/K) \cdot m \rceil), \quad i \in [K]$$

- ✓ $|\hat{x}^{(K)}| = m$ 이고, feasible (선택 연산자의 구성상 보장)

❖ 가변 크기 문제 (MIS)


- ✓ 솔루션 크기에 대한 추정치를 먼저 구함 $m_\theta(G, \hat{x}) := \sum_{u \in U(G)} p_{\theta,u}(G, \hat{x})$

$$\hat{x}^{(i)} \leftarrow f_G(\hat{x}^{(i-1)}, p_\theta(G, \hat{x}^{(i-1)}), \lceil \gamma(i/K) \cdot m_\theta(G, \hat{x}^{(i-1)}) \rceil), \quad i \in [K]$$

- ✓ 최종 반복 결과가 infeasible하면 직전 점수를 재사용

❖ 구성 → local optima → 반복 교정으로 탈출

✓ 매번 반복: p 비율만 무작위 유지(나머지 마스크) → 스케줄 $\gamma_p(r) = p + (1 - p) \cdot \gamma(r)$ 로 업데이트하여 K 스텝 재구성 → 개선 시 채택



Algorithm 1 Inference Algorithm

```

1: Input: multi-step decoding function
   Decode $_{f_G, \theta, K}(\cdot)$  with respect to instance  $G$ ,
   model parameters  $\theta$ , selection operator  $f_G$ , and
   number of iterations per decode  $K$ ; schedules  $\gamma(\cdot)$ 
   and  $\gamma_p(\cdot)$ ; total budget  $T$ ; masking rate  $p \in [0, 1]$ ;
   objective  $l(\cdot; G)$ 
2:  $\mathbf{x} \leftarrow \text{Decode}_{\theta, f_G, K}(\mathbf{0}, \gamma)$ 
3:  $\mathbf{x}_{\text{best}} \leftarrow \mathbf{x}$ 
4: for  $i = 1$  to  $\lfloor T/K \rfloor - 1$  do
5:    $\hat{\mathbf{x}} \leftarrow \text{RandomlyMask}(\mathbf{x}, p)$ 
6:    $\mathbf{x} \leftarrow \text{Decode}_{\theta, f_G, K}(\hat{\mathbf{x}}, \gamma_p)$ 
7:   if  $l(\mathbf{x}; G) < l(\mathbf{x}_{\text{best}}; G)$  then
8:      $\mathbf{x}_{\text{best}} \leftarrow \mathbf{x}$ 
9:   end if
10: end for
11: return  $\mathbf{x}_{\text{best}}$ 

```

✓ p 가 탐색↔활용 트레이드오프를 직접 제어

$p \downarrow$: 전역적으로 재최적화 (Global Exploration)

$p \uparrow$: 지역적으로 미세 조정 (Local Exploitation)

❖ 반복 구조

- ✓ T = 인스턴스 당 모델(히트맵) 호출 횟수, K = 라운드당 스텝 수
- ✓ 라운드 수: T/K = 구성 1회 + 교정 $(T/K - 1)$ 회
- ✓ 총 호출: 라운드 수 $\times$ 라운드당 호출 = $(T/K) \times K = T$

❖ 전체 흐름

- ✓ 학습: 비율 t 샘플링 $\rightarrow$ 최적해에서 t 비율만 남기고 나머지 마스킹 $\rightarrow$ 모델이 최적해 전체 복원 예측 $\rightarrow$ BCE로 θ 갱신
- ✓ 추론: 인코딩 1회 $\rightarrow$ 구성 $\text{Decode}(0, \gamma) \rightarrow [p \text{ 비율 유지 마스킹} \rightarrow \text{Decode}(\hat{x}, \gamma_p) \rightarrow \text{개선 시 채택}] \times \text{반복}$
- ✓ 이전의 고품질 부분구조가 다음 교정을 가이드 $\rightarrow$ 기억 강화형 탐색

❖ 제약이 복잡한 문제(VRP)의 처리

- ✓ HGS·LKH-3의 관행 차용: 용량 제약을 완화하고 비용함수의 페널티 항으로 흡수
- ✓ 교정 사이 페널티 2-opt 적용 $\rightarrow$ 제약 만족 + 품질 강화

❖ 문제 및 데이터 (표준 생성 절차)

- ✓ TSP (Traveling Salesman Problem)
: 100/500/1000: 단위 정사각형 내 균일 분포 노드
- ✓ CVRP(Capacitated Vehicle Routing Problem)
: 100/500/1000: 수요 $U\{1..9\}$, 차량 용량 50
- ✓ MIS (Maximum Independent Set)
: RB 그래프 [200-300 노드], ER 그래프 [700-800 노드, 연결 확률 0.15]

❖ 베이스라인

- ✓ 전통 solver: Concorde, LKH-3 (TSP) / HGS (CVRP) / KaMIS, Gurobi (MIS)
- ✓ 구성형 신경망: POMO, ICAM, BQ-NCO, LEHD, SIT, PolyNet, Poppy, ReLD, UDC
- ✓ 생성형: DIFUSCO, T2T, Fast T2T, GFlowNets / 탐색형: NeuOpt
- ✓ 평가: Obj(목적값), 최적 대비 Gap%, 시간

❖ TSP

Table 1: Results on TSP across various sizes.

METHOD	TSP-100			TSP-500			TSP-1000		
	OBJ.	GAP	TIME	OBJ.	GAP	TIME	OBJ.	GAP	TIME
Concorde (Applegate et al., 2006)	7.756	0.00%	12m*	16.55	0.00%	37.66m*	23.12	0.00%	6.65h*
LKH-3 (Helsgaun, 2017)	7.756	0.00%	33m*	16.55	0.00%	46.28m*	23.12	0.00%	2.57h*
BQ-NCO (bs16) (Drakulic et al., 2023)	7.757	0.016%	1m41s	16.637	0.551%	5m50s	23.436	1.374%	14m30s
LEHD (RRC 1000) (Luo et al., 2024)	7.756	0.0019%	7.87m	16.575	0.175%	37.54m	23.286	0.726%	3.35h
SIT (RRC 1000) (Luo et al., 2025)	–	–	–	–	–	–	23.206	0.381%	1.59h
Poppy (16) (Grinsztajn et al., 2023)	7.770*	0.07%*	1m*	–	–	–	–	–	–
PolyNet (sampling) (Hottung et al., 2025)	7.756	0.0006%	0.36m	–	–	–	–	–	–
PolyNet (EAS) (Hottung et al., 2025)	7.756	0.0000%	20.66m	–	–	–	–	–	–
DIFUSCO ($T_s=100$) (Sun & Yang, 2023)	7.76	0.06%	30m	16.69	0.87%	19.1m	23.42	1.31%	51.9m
Fast T2T ($T_s=5, T_g=5$) (Li et al., 2024)	7.76	0.01%	8.3m	16.58	0.21%	6.9m	23.22	0.42%	18.3m
MaskCO (T=320)	7.756	0.0000%	8s	16.546	0.0020%	6s	23.120	0.0071%	18s
MaskCO (T=640)	7.756	0.0000%	15s	16.546	0.0014%	12s	23.119	0.0051%	33s
MaskCO (T=1280)	7.756	0.0000%	30s	16.546	0.0012%	23s	23.119	0.0038%	1m6s
MaskCO (T=2560)	7.756	0.0000%	1m0s	16.546	0.0007%	43s	23.119	0.0027%	2m8s

- ✓ 이전 SOTA 신경망 solver 대비 optimality gap 99% 이상 감소 + 10배 속도 향상
- T=320: 전 스케일 사실상 최적($\leq 0.0071\%$)을 수 초~수십 초에 달성
 - 전통 solver(LKH-3)급 품질을 수백 배 빠르게 – TSP-1000: 2.57h $\rightarrow$ 18s

❖ CVRP

Table 2: Results on CVRP across various sizes.

METHOD	CVRP-100			CVRP-500			CVRP-1000		
	OBJ.	GAP	TIME	OBJ.	GAP	TIME	OBJ.	GAP	TIME
HGS (Vidal et al., 2012)	15.550	0.000%	13h	62.15	0.000%	55h	121.07	0.000%	197h
POMO (Kwon et al., 2020)	15.750	1.287%	8s	–	–	–	–	–	–
ICAM (Zhou et al., 2024a)	15.859	1.985%	5s	63.28	1.813%	28s	123.02	1.610%	1m56s
UDC (Zheng et al., 2025)	–	–	–	65.43	5.278%	5m56s	127.07	4.954%	4m25s
BQ-NCO (bs16) (Drakulic et al., 2023)	15.794	1.572%	2.74m	63.53	2.219%	5.86m	123.56	2.059%	7.73m
LEHD (RRC 1000) (Luo et al., 2024)	15.617	0.433%	9.53m	62.94	1.275%	38.27m	123.33	1.859%	1.83h
ReLD (augx8) (Huang et al., 2025)	15.785	1.509%	0.12m	64.16	3.241%	0.17m	125.06	3.297%	0.34m
SIT (RRC 1000) (Luo et al., 2025)	–	–	–	–	–	–	126.55	4.528%	1.23h
Poppy (32) (Grinsztajn et al., 2023)	15.73*	1.06%*	5m*	–	–	–	–	–	–
PolyNet (sampling) (Hottung et al., 2025)	15.627	0.496%	0.46m	–	–	–	–	–	–
PolyNet (EAS) (Hottung et al., 2025)	15.571	0.139%	25.40m	–	–	–	–	–	–
NeuOpt (D2A=5,T=40k) (Ma et al., 2023)	15.566	0.103%	4h49m	–	–	–	–	–	–
MaskCO (T=640)	15.586	0.232%	32s	62.66	0.813%	21s	122.03	0.798%	44s
MaskCO (T=1280)	15.577	0.176%	1m3s	62.59	0.714%	40s	121.85	0.644%	1m7s
MaskCO (T=2560)	15.571	0.135%	2m5s	62.53	0.608%	1m18s	121.69	0.514%	2m2s
MaskCO (T=5120)	15.567	0.111%	4m9s	62.47	0.514%	2m35s	121.63	0.460%	3m51s
MaskCO (T=10240)	15.563	0.086%	8m17s	62.43	0.448%	5m8s	121.60	0.438%	7m33s

✓ 하드 제약 문제에서도 품질·속도 동시 우위

- CVRP-500/1000: T=640으로 이미 기존 SOTA 대비 평균 품질 53% 개선 + 64% 속도 향상
- NeuOpt(0.103%, 4h49m) 대비 0.086%를 8m17s에 – 34.9배 고속 / T 증가 시 지속 개선

❖ MIS

- ✓ T=1k로 전체 SOTA 초과 - 평균 gap 72%↓, 3배 고속

Table 3: Results on MIS across various sizes.

METHOD	RB-[200-300]			ER-[700-800]		
	OBJ.	GAP	TIME	OBJ.	GAP	TIME
KaMIS (Lamm et al., 2016)	20.10*	–	1.4h	44.87*	–	52.1m
Gurobi (Gurobi Optimization, 2020)	19.98	0.01%	47.6m	41.28	7.78%	50.0m
Intel (Li et al., 2018)	18.47	8.11%	13.1m	38.80	13.43%	20.0m
DGL (Böther et al., 2022)	17.36	13.61%	12.8m	37.26	16.96%	22.7m
GFlowNets (Zhang et al., 2023)	19.18	4.57%	32s	41.14	8.53%	2.9m
DIFUSCO (Sun & Yang, 2023)	19.13	4.79%	20.5m	39.12	12.81%	21.7m
T2T (Li et al., 2023c)	19.38	3.53%	30.3m	41.41	7.72%	27.8m
Fast T2T (Li et al., 2024)	19.49	2.89%	4.7m	40.68	9.34%	1.5m
MaskCO (T=1k)	20.00	0.49%	44s	43.20	3.73%	1m21s
MaskCO (T=2k)	20.03	0.37%	1m27s	43.59	2.84%	2m42s
MaskCO (T=4k)	20.06	0.21%	2m54s	43.86	2.25%	5m24s
MaskCO (T=8k)	20.07	0.15%	5m48s	44.12	1.68%	10m48s
MaskCO (T=16k)	20.08	0.12%	11m36s	44.38	1.09%	21m36s
MaskCO (T=32k)	20.08	0.10%	23m12s	44.59	0.62%	43m12s

❖ 일반화

- ✓ 균일분포 학습만으로 TSPLIB에서 88% 개선

Table 4: Generalization on TSPLIB.

	ICAM	Fast T2T	NeuOpt	MaskCO
TSPLIB50-200	2.38%	0.28%	0.35%	0.033%
TSPLIB201-1000	6.49%	0.93%	–	0.115%

III Fine tuning & Alternative decoding

❖ 마스킹으로 학습된 모델을 재학습 없이 다른 추론 방식에 그대로 사용

- ✓ AR: 경로의 끝 노드에 붙은 간선만 선택
- ✓ Bidirectional AR: 경로를 양쪽 끝에서 연장할 수 있게 한 것 (AR의 변형)
- ✓ Relaxed AR: “경로가 이어져 있어야 한다”는 제약을 풀고, 매 스텝 전역에서 가장 확신이 높은 간선 1개 삽입
- ✓ 1에폭 파인튜닝만으로 consistency 모델로 전환도 가능

→ 지도학습 AR SOTA를 능가

Table 6: Results of fine-tuning and alternative decoding. S: number of samples; T_s : sampling steps.

DECODING METHOD	TSP-100			TSP-500			TSP-1000		
	OBJ.	GAP	TIME	OBJ.	GAP	TIME	OBJ.	GAP	TIME
Direct Evaluation									
AR (aug×8)	7.756	0.0004%	19s	16.549	0.018%	1m42s	23.136	0.078%	10m4s
AR (2Opt, aug×8)	7.756	0.0004%	19s	16.548	0.012%	1m42s	23.125	0.030%	10m4s
Bidirectional AR (aug×8)	7.756	0.0007%	19s	16.549	0.021%	1m42s	23.215	0.419%	10m4s
Bidirectional AR (2Opt, aug×8)	7.756	0.0006%	19s	16.549	0.019%	1m42s	23.141	0.098%	10m4s
Relaxed AR (aug×8)	7.756	0.0016%	19s	16.549	0.019%	1m41s	23.128	0.043%	10m4s
Relaxed AR (2Opt, aug×8)	7.756	0.0016%	19s	16.548	0.014%	1m41s	23.125	0.028%	10m4s
1-Epoch Finetuning									
Consistency (S=8, T_s =64) (Li et al., 2024)	7.756	0.0008%	15s	16.552	0.040%	29s	23.148	0.131%	2m13s
Consistency (S=8, T_s =256) (Li et al., 2024)	7.756	0.0004%	1m0s	16.550	0.025%	1m47s	23.143	0.107%	8m54s

→ 특정 추론법이 아닌 '표현' 자체를 학습했다는 증거

❖ 최적해가 아닌 저품질 레이블로 학습

- ✓ Stage 1: 저품질 휴리스틱 레이블(2-opt, 128 재시작)로 표준 지도학습 (150 에폭이면 수렴)
- ✓ Stage 2: self pseudo-labeling $\leftrightarrow$ 경량 파인튜닝(표준의 1/60 스텝) 반복

Table 9: Optimal-solution-free training on TSP-100 and 500 (T=2560). D0 denotes training on 2-opt labels; Dx ($x \geq 1$) denotes self-training using pseudo-labels from $D(x-1)$.

METHOD	TSP-100		TSP-500	
	OBJ.	GAP	OBJ.	GAP
2Opt (128 runs)	7.905	1.920%	17.703	6.994%
MaskCO (D0)	7.756	0.001%	16.606	0.362%
MaskCO (D1)	7.756	0.000%	16.561	0.089%
MaskCO (D2)	7.756	0.000%	16.556	0.059%

Table 10: Optimal-solution-free training on TSP-1000 with T=2560. "Gen." indicates training on TSP-500 and testing on TSP-1000.

METHOD	TSP-1000	
	OBJ.	GAP
2Opt (128 runs)	25.052	8.366%
MaskCO (Gen. as D0)	23.288	0.733%
MaskCO (D1)	23.197	0.342%
MaskCO (D2)	23.186	0.295%

- ground-truth 최적해 불필요: 최적해 라벨 의존 해소
- 2-opt gap 1.9% vs D0 0.001% - 저품질 레이블에서도 좋은 성능을 보임

❖ 백본: Transformer vs GCN

Table 7: Ablation studies on architecture.

T	BACKBONE	TSP-500	TSP-1000
320	Transformer	0.0020%, 6s	0.0071%, 18s
	GCN	0.0212%, 40s	0.0457%, 2m24s
640	Transformer	0.0014%, 12s	0.0051%, 33s
	GCN	0.0141%, 1m15s	0.0324%, 4m39s
1280	Transformer	0.0012%, 23s	0.0038%, 1m6s
	GCN	0.0107%, 2m26s	0.0229%, 9m19s

❖ 마스킹 효과: 백본을 GCN으로 통일하고 학습 방식만 비교

Table 8: Ablation studies on mask modeling.

METHOD	TSP-500	TSP-1000
DIFUSCO	0.87%, 19.1m	1.31%, 51.9m
Fast T2T	0.21%, 6.9m	0.42%, 18.3m
MaskCO-GCN (T=320)	0.0212%, 40s	0.046%, 2m24s
MaskCO-GCN (T=640)	0.0141%, 1m15s	0.032%, 4m39s
MaskCO-GCN (T=1280)	0.0107%, 2m26s	0.023%, 9m19s

❖ 교정 메커니즘 효과

Table 5: Ablation studies on the correction mechanism.

CONFIG.	TSP-500		
	OBJ.	GAP	TIME
w/o corr. (T=K=1)	16.689	0.8656%	<1s
w/o corr. (T=K=8)	16.563	0.1015%	<1s
w/o corr. (T=K=64)	16.556	0.0606%	1s
w/o corr. (T=K=320)	16.554	0.0520%	6s
w/ corr. (T=320, K=1)	16.546	0.0020%	6s

- 동일 예산(T=320)에서 교정 유무만으로 gap 26배 차이

❖ 학습 시간 비교 (A100 1장)

Table 25: Comparison of training resource usage for TSP using a single A100 GPU.

	TSP-100	TSP-500	TSP-1000
T2T	8.6Day	2.7Day	5.1Day
Fast T2T	20.3Day	5.9Day	13.5Day
MaskCO	≤2Day	≤1Day	≤1Day

❖ 강점

- ✓ 데이터 효율: 해 하나 → 지수적 학습 신호 (라벨 비싼 CO에서 결정적)
- ✓ RL 없는 안정적 지도학습 (sparse reward·credit assignment 문제 회피)
- ✓ 구성과 개선을 단일 모델·단일 학습목표로 통합
- ✓ 인코더 1회 + 얇은 디코더 반복 → 교정 수백 회가 저비용
- ✓ 표현이 전이됨: AR·consistency 등 타 추론법으로 즉시/1에폭 전환
- ✓ self-training으로 최적해 라벨 없이도 SOTA 초과

❖ 한계 및 논의

- ✓ 기본 세팅은 고품질 reference 해 필요 (LKH 등) → self-training이 완화하나 초기 휴리스틱은 여전히 필요
- ✓ VRP는 교정 사이 페널티 2-opt에 의존 → 순수 신경망이 아닌 하이브리드로 읽는 것이 정확
- ✓ 그래프 위 선택형 문제(TSP·CVRP·MIS) 중심 검증 → 순서·시간 구조가 본질인 문제(예: 스케줄링)는 미검증
- ✓ self-training 반복의 수렴·개선 보장은 경험적 (이론 분석 부재)

❖ 기여

- ① Masked generation을 NCO의 근본 학습 패러다임으로 제안 → 최적화를 solution-level self-supervised 학습으로 재정의
- ② 학습 목표를 그대로 활용하는 mask-and-reconstruct 추론 → 효율적 탐색 행동을 시뮬레이션
- ③ TSP·CVRP·MIS에서 SOTA 달성: gap 99%↓ + 10배 속도, 학습 비용 1/13, 일반화 88%↑